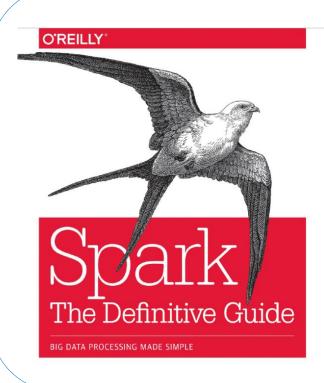
# **Contact Spark Developer**

# Introdução ao Apache Spark

**Arquitetura do Spark - Parte 2** 



## Capítulos Abordados

- 2. A Gentle Introduction do Spark
  - Partitions
  - Transformations / Actions
  - Spark UI
- 15. How Spark Runs on a Cluster
  - Jobs / Stages / Tasks



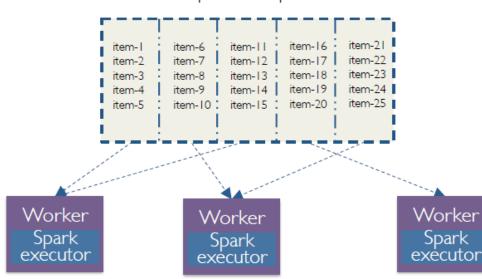






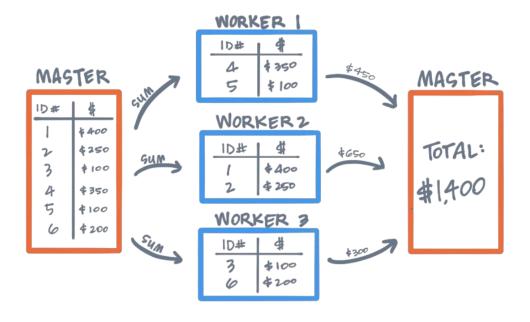
## **Dados Particionados**

RDD split into 5 partitions



val rdd = sc.parallelize(1 to 25, 5) // 25 items, 5 partitions

#### Processamento Paralelo e Distribuído



val money = List(400,250,100,350,100,200)
val sum\_money = sc.parallelize(money, 3).sum()





## Transformations and Actions/>

## **Transformações**

#### **Narrow**

- map
- filter
- flatMap
- mapValues

#### Wide

- groupByKey
- reduceByKey
- distinct
- join
- repartition

# "Wide" (shuffle) deps: map, filter join with inputs co-partitioned groupByKey join with inputs not co-partitioned

## **Ações**

### **Lazy Evaluation**

Transformações (Criam o plano lógico)



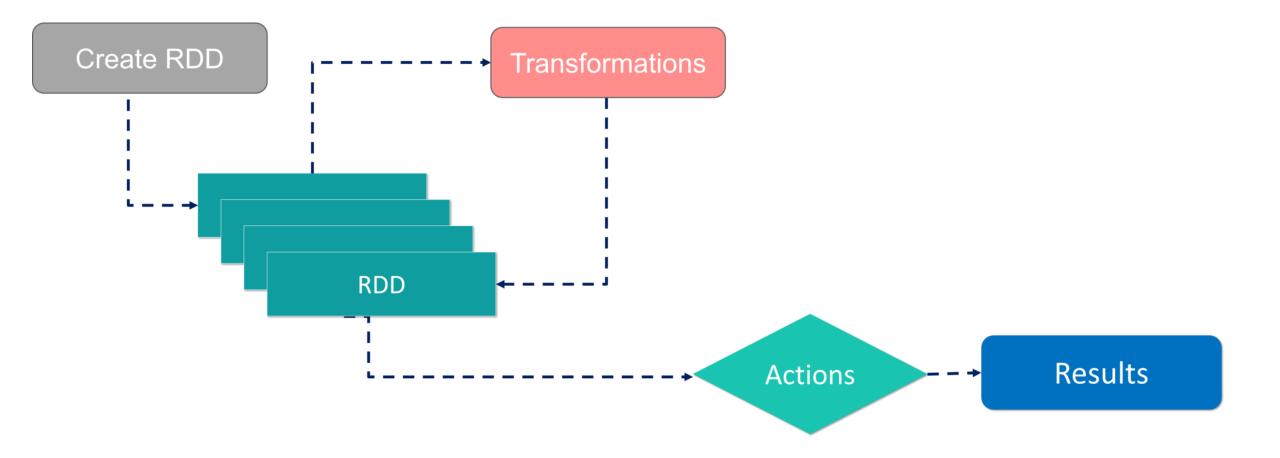
Action (Desencadeia a computação)

#### Tipos de ações

- Disponibilizar dados no console
- Transformar dados em objetos nativos da linguagem (ex. List)
- Persistir os dados no output final (HDFS, SQL Server, Hive, Hbase, Kafka, etc.











# <Jobs, stages and tasks/>

#### Jobs:

Criado a partir de uma ação.

#### **Exemplos:**

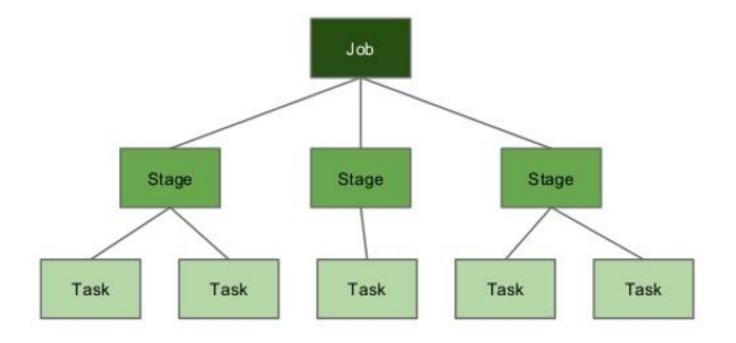
- df.show()
- rdd.count()
- df.write.insertInto()

## Stages:

Grupo de tarefas iguais sendo executadas em paralelo

#### Tasks:

Unidade de computação aplicada a uma única partição





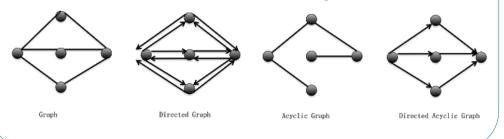


# <Jobs, stages and tasks/>

## **Directed Acyclic Graph (DAG)**

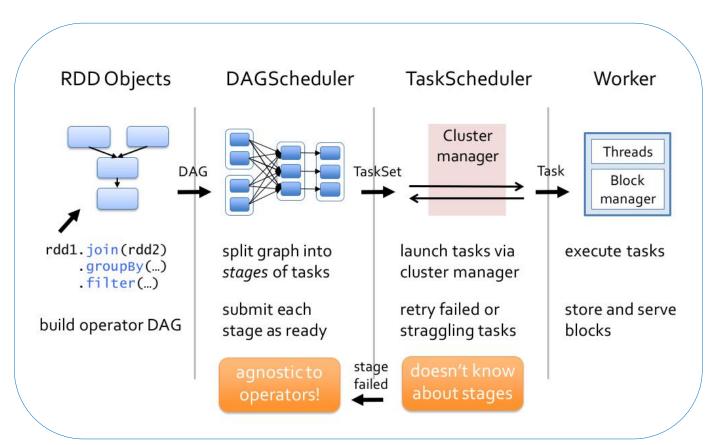


**Arestas: Transformações** 



#### **DAG Optimizer**

Rearranjo da ordem das transformações para alcançar o mesmo resultado

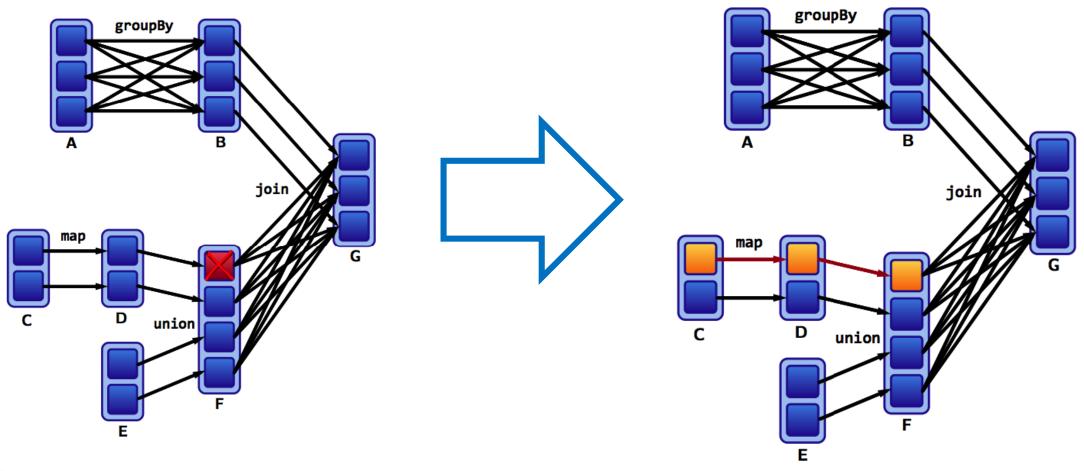








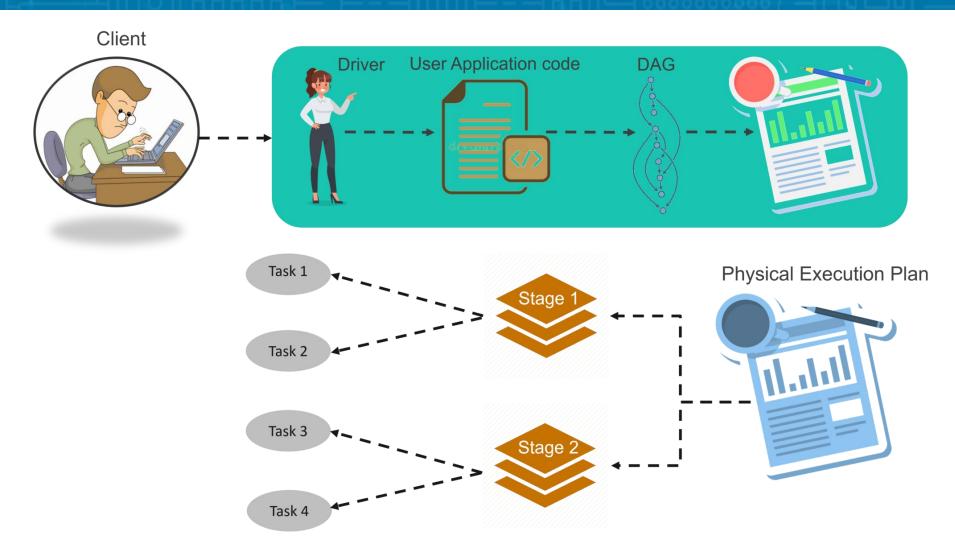
## Recomputação apenas dos dados perdidos (Partição perdida)







# Putting all together.../>









# **Spark User Interface**

Acesso: <a href="http://localhost:4040">http://localhost:4040</a> (default)

- 1. Jobs
- 2. Stages
- 3. Storage (RDDs Persistidos)
- Enviroment (Configurações da App.)
- 5. Executors (Estado dos executores e do Driver da App).

